

Récapitulatif du Projet Hephaestus

Contexte et Logistique

- **École** : {EPITECH}
- **Dates du projet** : Du 8 janvier au 16 janvier 2026
- **Groupe** : 3 à 5 étudiants
- **Objectif** : Concevoir un agent conversationnel intelligent capable d'exécuter des actions via des outils externes en utilisant le Model Context Protocol (MCP) ou un protocole similaire

Objectifs Techniques

- **Livrable** : Un prototype fonctionnel combinant interaction en langage naturel, orchestration serveur d'actions automatisées et interface web
- **Thème** : Libre choix (exemple suggéré : gestion de données aéroportuaires)
- **Fonctionnalités** : Le backend doit fournir des outils permettant au LLM d'accéder à des données en direct (live data)
- **Méthode d'acquisition de données** : Privilégier le web scraping en direct (Selenium ou Zenderiver) plutôt que l'implémentation manuelle de multiples API pour garantir la flexibilité géographique (ex: Tokyo, Séoul, Madrid)

Architecture du Système

- **Frontend** : Interface utilisateur pour interagir avec le chatbot
- **Backend** : Orchestrateur entre le frontend et le Runtime IA, intégrant le protocole de gestion des outils ("Tools")
- **AI Runtime** : Exécution du modèle local (Ollama ou llama-server) pour traiter les

requêtes et décider de l'utilisation des outils

Stack Technique Préconisée

- **Backend** : Python (FastAPI, Flask)
- **Frontend** : TypeScript (React, Angular, Vue.js, Svelte)
- **Local AI Runtime** : Ollama
- **LLM autorisés** : DeepSeek R1, GPT-OSS, Llama 3.x, Mistral, Qwen3
- **Contrainte majeure** : Utilisation obligatoire d'un modèle local et open-source ; aucun crédit API payant ne sera fourni

Spécifications du Modèle

- **Référence de test** : Qwen3 1.7B testé avec un contexte de 40k
- **Taille de contexte** : Minimum 32k recommandé pour l'envoi de pages web brutes au LLM
- **Qualité** : Un nombre de paramètres et une taille de contexte élevés sont encouragés pour limiter les hallucinations

Évaluation (Présentation)

- **Durée** : 20 minutes de présentation suivies de 5-10 minutes de Q&A
- **Éléments requis** :
 - Démonstration fonctionnelle (site et chatbot)
- Explication de l'architecture technique et du flux de données
- Analyse critique des choix techniques et des difficultés rencontrées

- Discussion sur les perspectives d'évolution du projet
- **Condition impérative** : Participation active de tous les membres sous peine d'échec individuel